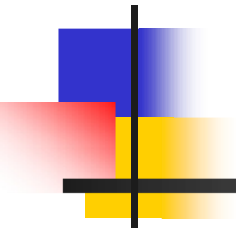

第4章 语料库与语言知识库

4.1 基本概念

4.1 基本概念

输入

处理模块

输出

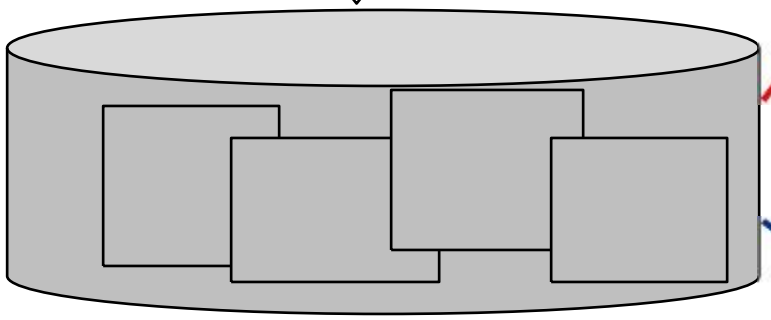

语言数据库或知识库

大规模语言数据：

- 模型参数训练
- 评测标准

NLP中知识库包括：

- 词汇语义库
- 词法、句法规则库
- 常识库等等

4.1 基本概念

◆语料库(corpus)

- 语料库(corpus) 就是存放语言材料的仓库 (语言数据库)。
- 基于语料库进行语言学研究—语料库语言学 (corpus linguistics)

4.2 语料库的类型

4.2 语料库的类型

- 按语言种类划分
  - 单语的
  - 双语的或多语的

    篇章对齐 / 句子对齐 / 结构对齐

- 是否标注？
  - —具有词性标注
  - —句法结构信息标注(树库)
  - —语义信息标注

4.2 语料库的类型

◆平行语料库

平行语料库是指在两种或多种语言之间的平行采样和加工，例如，机器翻译中的双语对齐语料库

C: 早晨好！

E: Good morning.

C: 早晨1 好2 !3

E: Good2 morning1 .3

C: 您能给我一杯咖啡吗？

E: Could you give me a cup of coffee?

…… ……

4.3 典型语料库介绍

4.3 典型语料库介绍

◆宾夕法尼亚大学（UPenn）树库(Tree Bank)

- 美国宾夕法尼亚大学计算机系 M. Marcus 教授主持
- **1993**年完成约**300**万词次英语句子的语法结构标注
- **2000**年完成第一版汉语树库，约**10**万词次，**4185**个句子
- **Chinese Tree Bank (CTB)** 中汉语词性被划分为**33**类，**23**类句法标记(Syntactic tags)

4.3 典型语料库介绍

◆ 例 句：他还提出一系列具体措施的政策要点。

词性标注：他/**PN** 还/**AD** 提出/**VV** 一/**CD** 系列/**M** 具体/**JJ** 措施/**NN** 和/**CC** 政策/**NN** 要点/**NN** 。/**PU**

4.3 典型语料库介绍

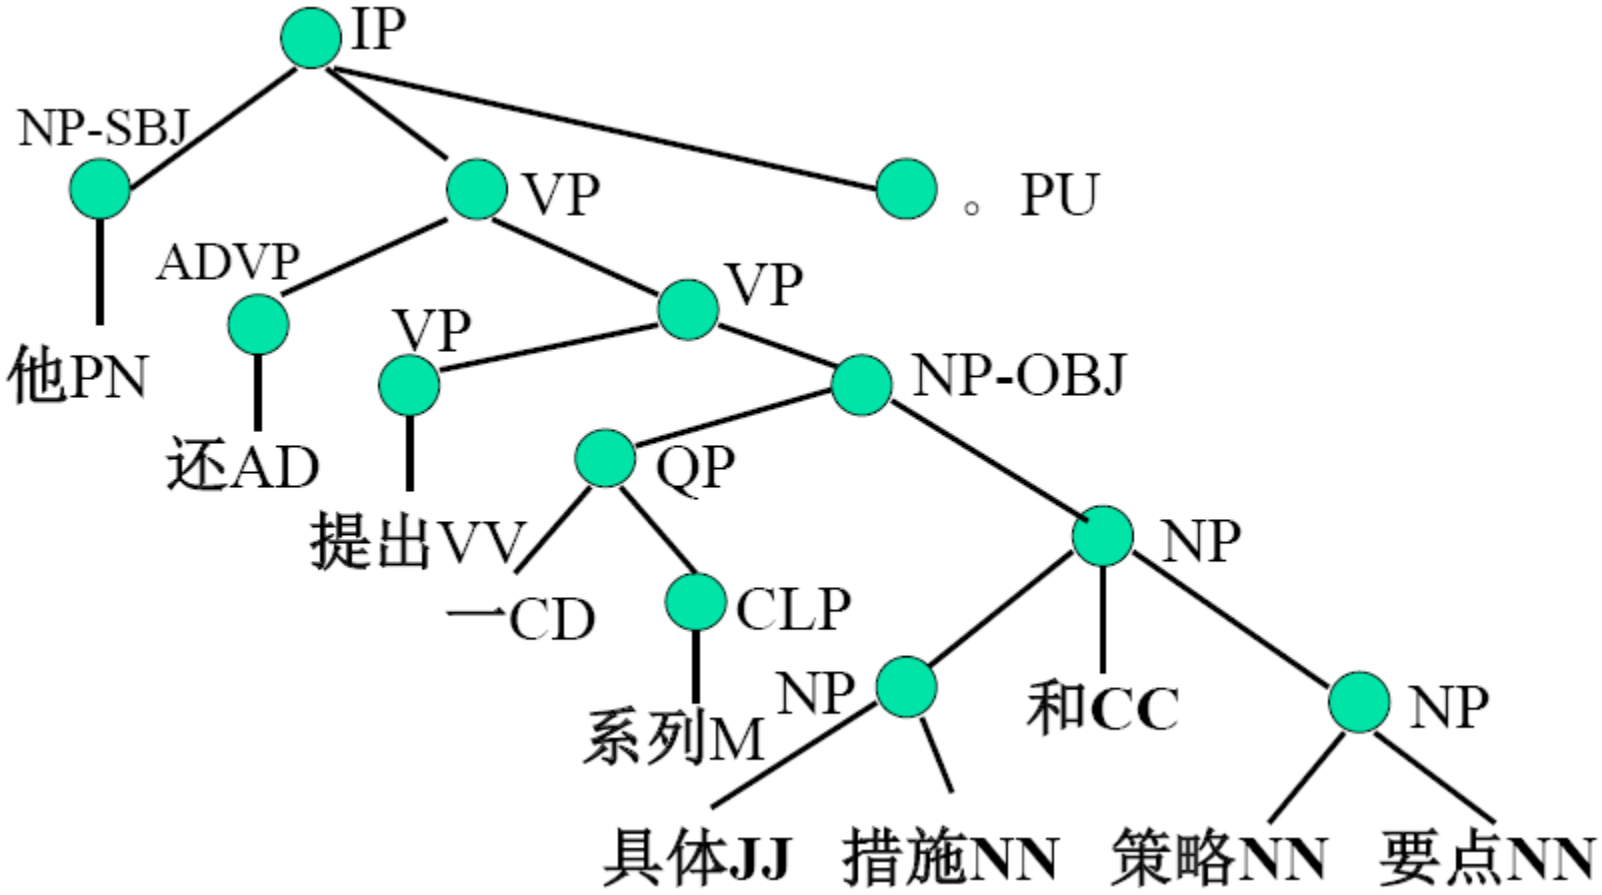
IP
NP-SBJ
VP
。PU
他PN
ADVP
VP
VP
还AD
NP-OBJ
提出VV
QP
NP
一CD
CLP
NP
和CC
NP
系列M
NP
具体JJ
措施NN
策略NN
要点NN

4.3 典型语料库介绍

- 北京大学开发的**CLKB**
  - 现代汉语语法信息词典：**8**万词、**360**万语法属性描述
  - 汉语短语结构规则库：**600**多条语法规则
  - 现代汉语多级加工语料库：实现词语切分并标注词类的基本标注语料库**1.5**亿字，其中精加工的有**5200**万字，标注义项的有**2800**万字
  - 多语言概念词典：**10**万个以同义词集表示的概念
  - 平行语料库：含对译的英汉句对**100**万
  - 多领域术语库：有**35**万汉英对照术语

4.3 典型语料库介绍

多级加工语料样例：

咱们/r 中国/ns 这么/r 大/a 的/u 一个/m 多/a 民族/n 的/u 国家/n 如果/c 不/d 团结/a ，/w 就/d 不/d 可能/v 发展/v 经济/n ，/w 人民/n 生活/n 水平/n 也/d 就/d 不/d 可能/v 得到/v 改善/vn 和/c 提高/vn 。/w

4.3 典型语料库介绍

◆口语语料库：BTEC (Basic Traveler's Expression Corpus)

目标是开展语音翻译的国际合作研究，开发实用的语音翻译技术

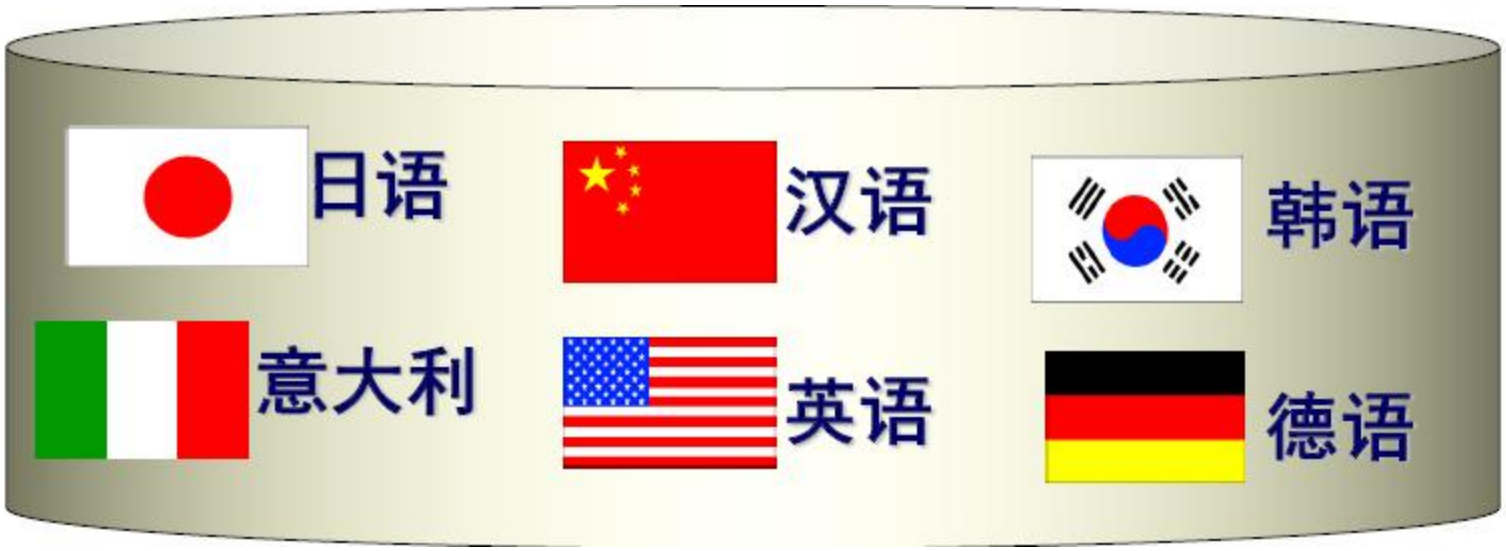

4.3 典型语料库介绍

◆CASIA-CASSIL 语料库

- 选自15000余段汉语电话(语音)对话录音
- 每段平均不少于90秒、10个回合(turns)，如：

场景	旅馆	餐馆	机场	全部	平均
对话个数	206	263	323	792	--
回合个数	3,676	4,389	4,993	13,058	16.5
话语个数	7,352	8,778	9,986	26,116	33.0
字数	78,950	85,491	110,135	274,576	10.5
词数	57,800	44,112	78,368	180,280	6.9

- 基于文字的对话语料

4.4 词汇知识库

4.4 词汇知识库

- **WordNet (http://wordnet.princeton.edu/)**
  - 普林斯顿大学(Princeton University) 认知科学实验室 GeorgeA. Miller 教授领导开发。
  - 开发目的：解决词典中同义信息的组织问题
  - 目前规模：95600 英语词条，其中，51500个简单词，44100 个搭配词。70100个词义(同义词集合)。
  - 五大类词汇：名词、动词、形容词、副词、虚词。

4.4 词汇知识库

- 特色：根据词义（而不是词形）组织词汇信息，从某种意义上讲，它是一部语义词典。
- **WordNet** 按语义关系组织：语义关系看作是同义词集合之间的一些指针，语义关系是双向的。

4.4 词汇知识库

- **4** 种语义关系：
  - 同义关系**(synonymy)**
  - 反义关系**(antonymy)**
  - 上下位关系**(hypernmy/ hyponym)**或称从属/上属关系：如：{枫树}是{树}的下位，{树}是{植物}的下位。
  - 部分关系**(meronymy)**或称部分/整体关系。

4.4 词汇知识库

- 使用wordnet的基本功能 http://wordnetweb.princeton.edu/perl/webwn

Word to search for: java Search WordNet

Display Options: (Select option to change) Change

Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations

Display options for sense: (frequency) {offset} <lexical filename > [lexical file number] (gloss) "an example sentence"

Display options for word: word#sense number (sense key)

Noun

- (2){08928021} <noun.location>[15] S: (n) **Java#1 (java%1:15:00::)** (an island in Indonesia to the south of Borneo; one of the world's most densely populated regions)
- (1){07945759} <noun.food>[13] S: (n) coffee#1 (coffee%1:13:00::), **java#2 (java%1:13:00::)** (a beverage consisting of an infusion of ground coffee beans) *"he ordered a cup of coffee"*
- {06913829} <noun.communication>[10] S: (n) **Java#3 (java%1:10:00::)** (a platform-independent object-oriented programming language)
  - ***direct hypernym*** / *inherited hypernym* / *sister term*
    - {06913460} <noun.communication>[10] S: (n) object-oriented programming language#1 (object-oriented_programming_language%1:10:00::), object-oriented programing language#1 (object-oriented_programing_language%1:10:00::) ((computer science) a programming language that enables the programmer to associate a set of procedures with each type of data structure) *"C++ is an object-oriented programming language that is an extension of C"*

4.4 词汇知识库

- **WordNet** 的应用

词汇消歧，语义推理，理解等。

例如：食堂 没 地方，我 在 饭馆 吃 了 蛋 炒饭。

“地方”的三种意思：

#指地理位置　　如：在祖国各个地方

#指空间　　如：没地方

#指部分　　如：他说的有些地方不对

4.4 词汇知识库

三个含义在两棵不同的名词集成语义树上，其中一个树的部分：

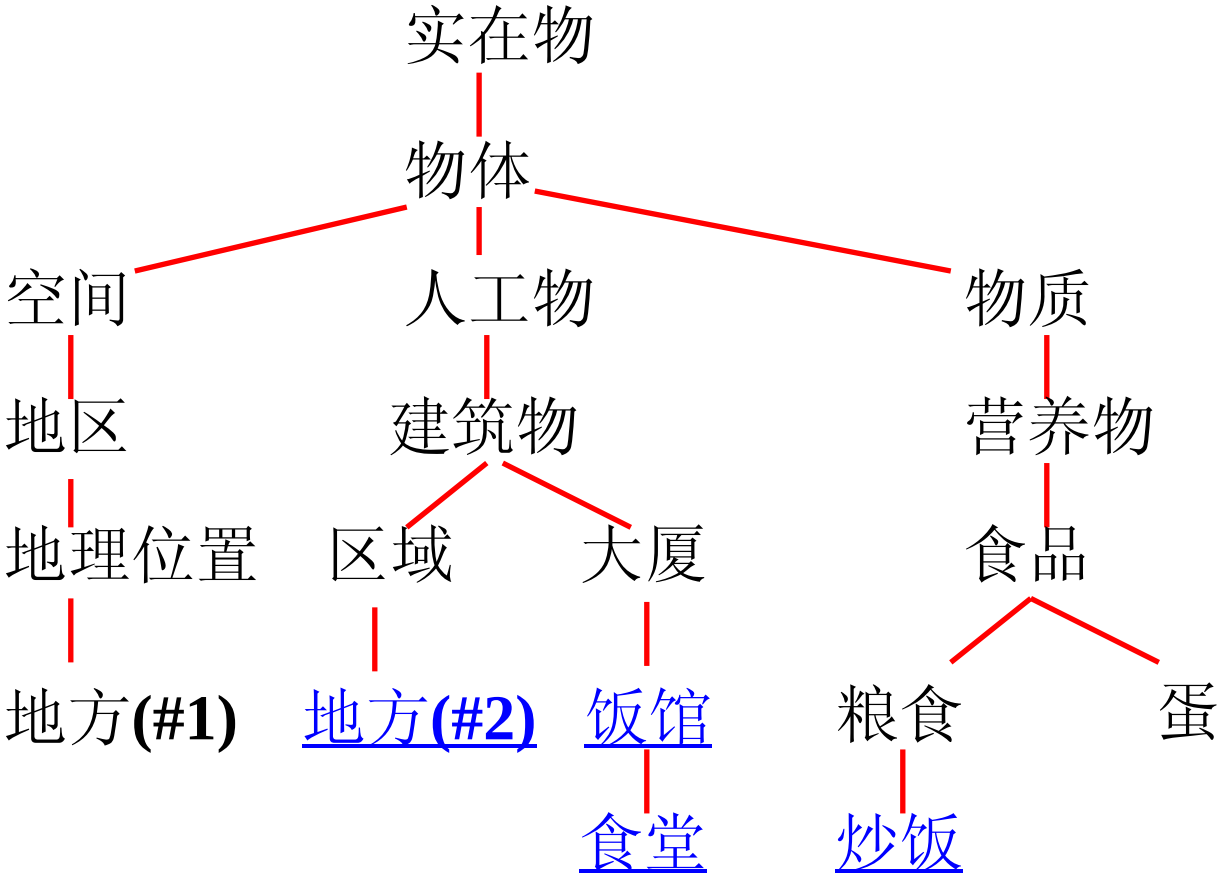

4.4 词汇知识库

- 使用wordnet的基本功能

使用NLTK之WordNet 接口

```
>>> dog = wn.synset('dog.n.01')
>>> cat = wn.synset('cat.n.01')
```

```
>>> dog.path_similarity(cat)
0.2000000000000001
>>> cat.path_similarity(cat)
1.0
```

```
>>> dog = wn.synset('dog.n.01')
>>> dog.hypernyms()          #上位词集合
[Synset('domestic_animal.n.01'), Synset('canine.n.02')]
>>> dog.root_hypernyms() #得一个最一般的上位（或根上位）同义词集
[Synset('entity.n.01')]
>>> dog.hyponyms()           #下位词集合
[Synset('puppy.n.01'), Synset('great_pyrenees.n.01'),
Synset('basenji.n.01'), Synset('newfoundland.n.01'),
Synset('lapdog.n.01'), Synset('poodle.n.01'),
Synset('leonberg.n.01'), Synset('toy_dog.n.01'),
Synset('spitz.n.01'), Synset('pooch.n.01'), Synset('cur.n.01'),
Synset('mexican_hairless.n.01'), Synset('hunting_dog.n.01'),
Synset('working_dog.n.01'), Synset('dalmatian.n.02'),
```

4.4 词汇知识库

◆ 知网(HowNet) (~~http://www.keenage.com~~)

➢1988年由董振东教授提出：

(1) **NLP**系统最终需要更强大的知识库的支持。

(2) 知识是一个系统，是一个包含着各种概念与概念之间的关系，以及概念的属性与属性之间的关系的系统。

4.4 词汇知识库

◆知网描述了下列各种关系：

(a) 上下位关系 **(**由概念的主要特征体现）

(b) 同义关系

(c) 反义关系

(d) 对义关系

(e) 部件-整体关系

(f) 属性-宿主关系

(g) 材料-成品关系

4.4 词汇知识库

◆知网描述了下列各种关系：

(h) 施事/经验者/关系主体-事件关系（由在事件前标注 * 体现，如“医生”，“雇主”等）

(i) 受事/内容/领属物等-事件关系（由在事件前标注 **$** 体现，如“患者”，“雇员”等）

(j) 工具-事件关系（由在事件前标注 * 体现，如“手表”，“计算机”等）

(k) 场所-事件关系（由在事件前标注 @ 体现，如“银行”，“医院”等）

(l) 时间-事件关系（由在事件前标注 @ 体现，如"假日"，"孕期"等）

4.4 词汇知识库

◆知网描述了下列各种关系：

(m) 值-属性关系（直接标注无须借助标识符，如“蓝”，“慢”等）

(n) 实体-值关系（直接标注无须借助标识符，如“矮子”，“傻瓜”等）

(o) 事件-角色关系（由加角色名体现，如“购物”，“盗墓”等）

(p) 相关关系（由在相关概念前标注 # 体现，如“谷物”，“煤田”等）

4.4 词汇知识库

◆词语例子：

NO.=000001

W_C=打

G_C=V

E_C=~酱油，**~**张票，**~**饭， 去**~**瓶酒， 醋**~**来了

W_E=buy 英语

G_E=V

E_E=

DEF=buy|买 概念定义

4.4 词汇知识库

NO.=015492
W_C=打
G_C=V
E_C=~毛衣，**~**毛裤，**~**双毛袜子，**~**草鞋，**~**一条围巾，**~**麻绳，**~**条辫子
W_E=knit
G_E=V
E_E=
DEF=weave|辫编

Thanks

谢谢！